clinVar EDA

CLINVAR VCF EDA

Table of Contents

1 Introduction

3 Project information

4 Data acquisition

5 Data preprocessing

6 EDA: CLNSIG

7 EDA: Pathogenic

9 EDA: Gene

10 Tableau Dashboard

11 Contact

clinVar

- NCBI의 데이터베이스 중 하나로, 변이에 대한 데이터를 담고 있다.

- 데이터는 주기적으로 업데이트 되며, vcf파일로 제공된다. vcf파일은 grch 37과 grch 38 두 종류가 있다.

- VCF파일에는 이 변이가 어떤 변이인지, 어떤 염기가 어떻게 변이됐는지에 대한 정보가 담겨져 있다.

Project information

Data resource: clinVar

Liblaries

- Numpy
- Pandas
- Matplotlib
- Seaborn
- gzip

Visualiation tool

- Tableau

Project Information

1 → Data acquisition

2 → Data transformation

3 → Preprocessing

4 → EDA

5 → Tableau dashboard

1

Data acquisition

clinVar VCF파일 입수

GRCh37, 20260208

2

Data Transformation

VCF파일을 CSV파일로 변환

INFO칼럼은 딕셔너리로 파싱한 다음 내장된 데이터를 데이터프레임으로 변환

1

Data acquisition

clinVar VCF파일 입수

GRCh37, 20260208

2

Data Transformation

VCF파일을 CSV파일로 변환

INFO칼럼은 딕셔너리로 파싱한 다음 내장된 데이터를 데이터프레임으로 변환

CLNCIG Group

CLNSIG 그룹 내 분포 및 염색체 종류별 비중

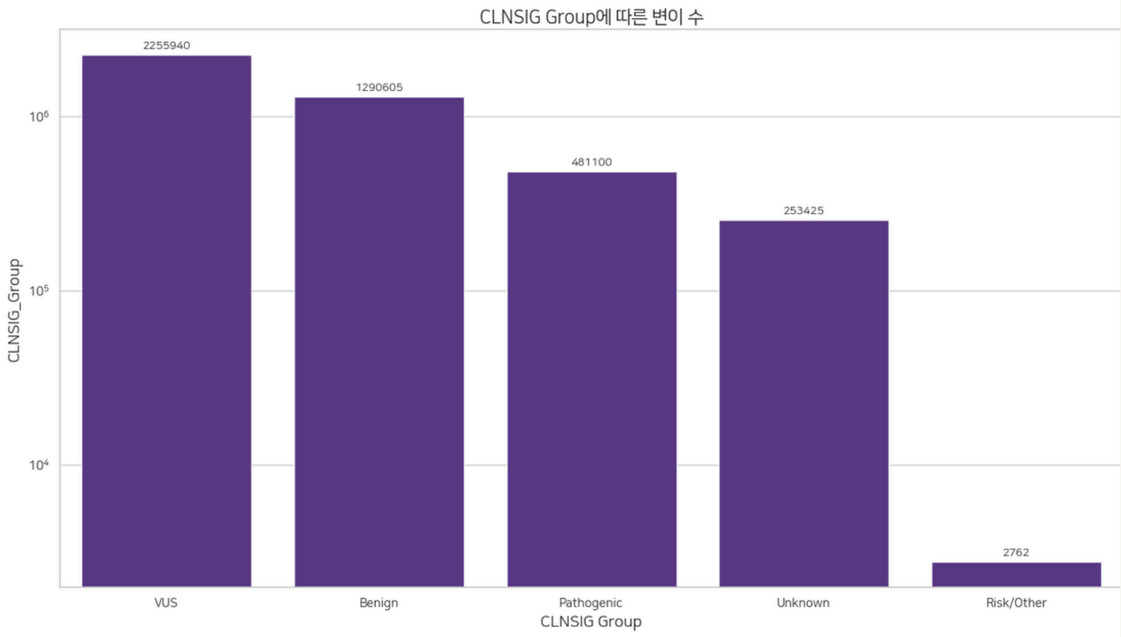

전체 데이터 내 CLNSIG 유형별 분포

VUS가 가장 많았고, 그 다음으로 Benign이 가장 많음

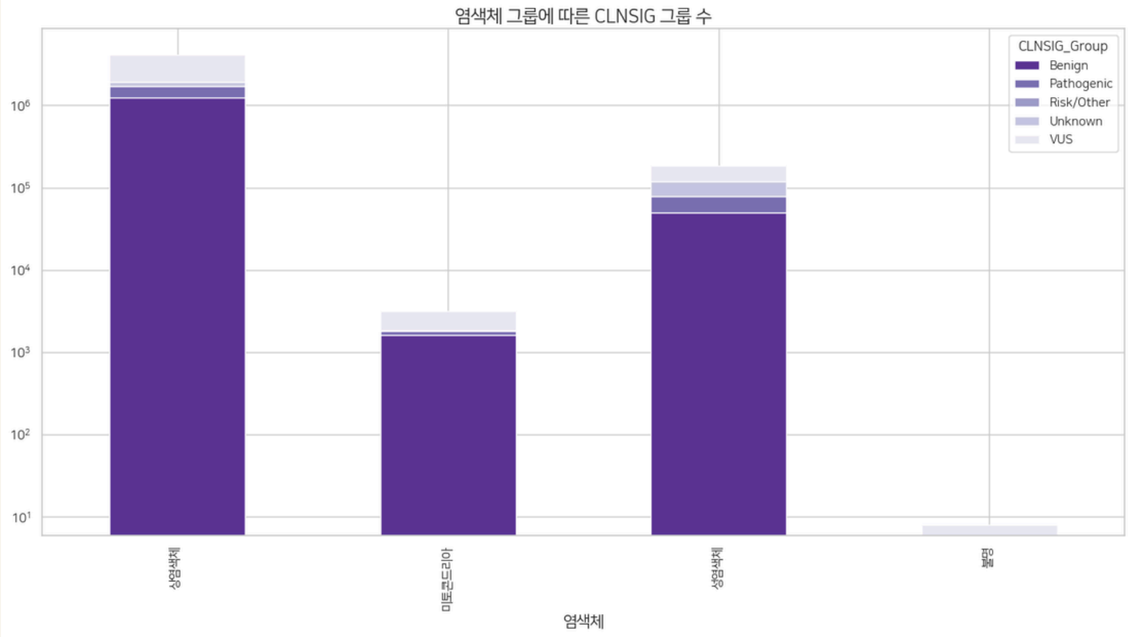

염색체 종류에 따른 CLNSIG 유형 비중

염색체별로 상이한 부분이 있었으나, Benign이 가장 많았음

Pathogenic ratio

염색체 카테고리별 Pathogenic 변이 비율

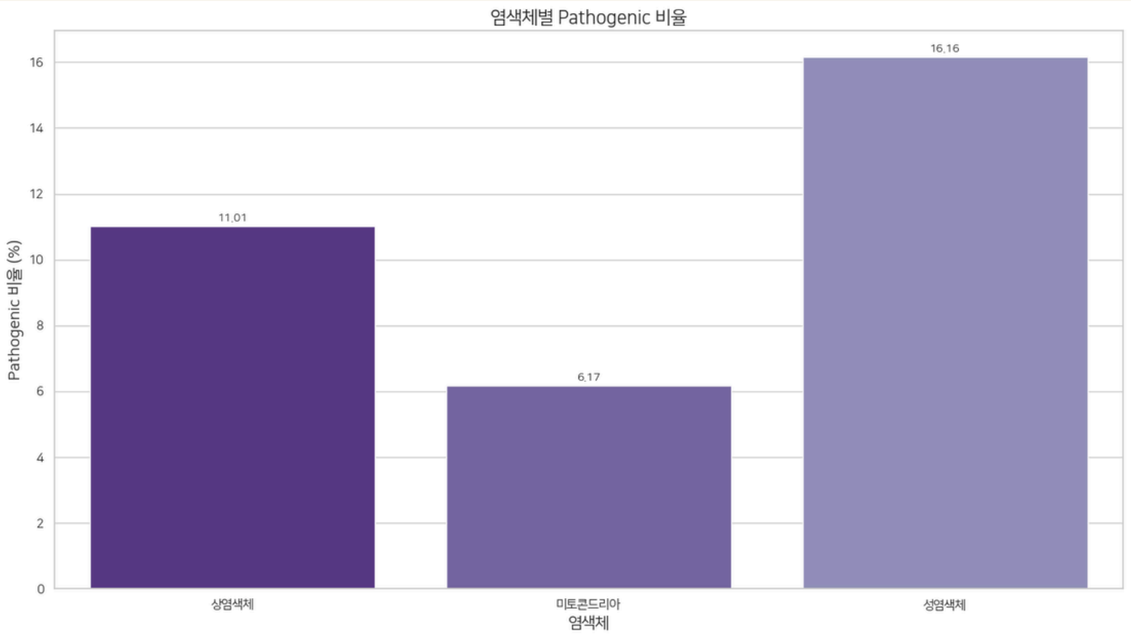

염색체별 Pathogenic 변이 비율

성염색체, 상염색체, 미토콘드리아순으로 비율이 높음

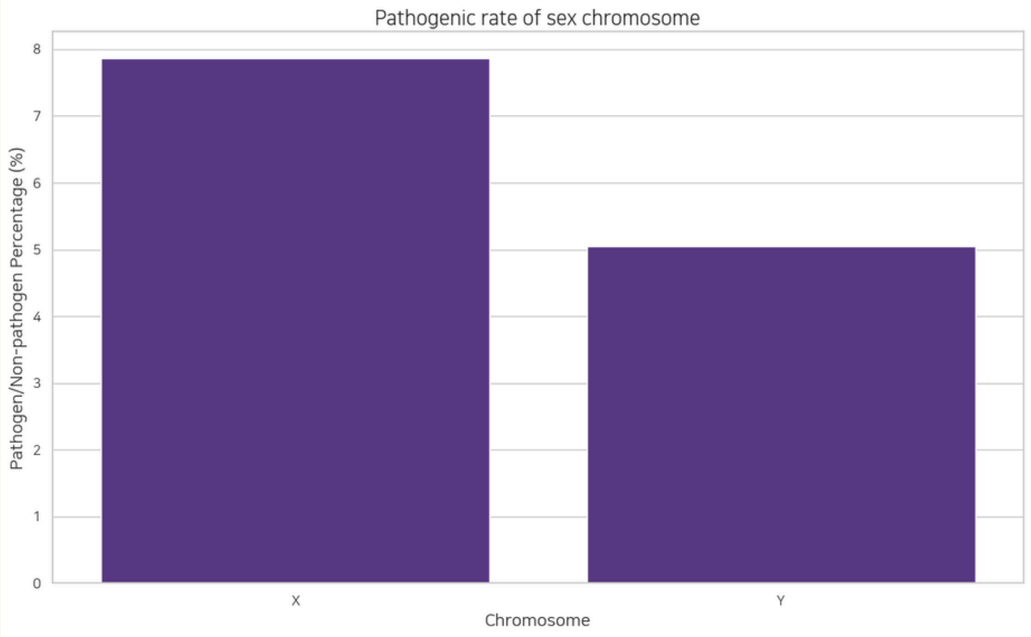

성염색체의 Pathogenic 변이 비율 차이

X염색체가 Y염색체에 비해 약 2~5%가량 더 높음

CLNVC

Pathogenic한 변이 내 CLNVC 유형

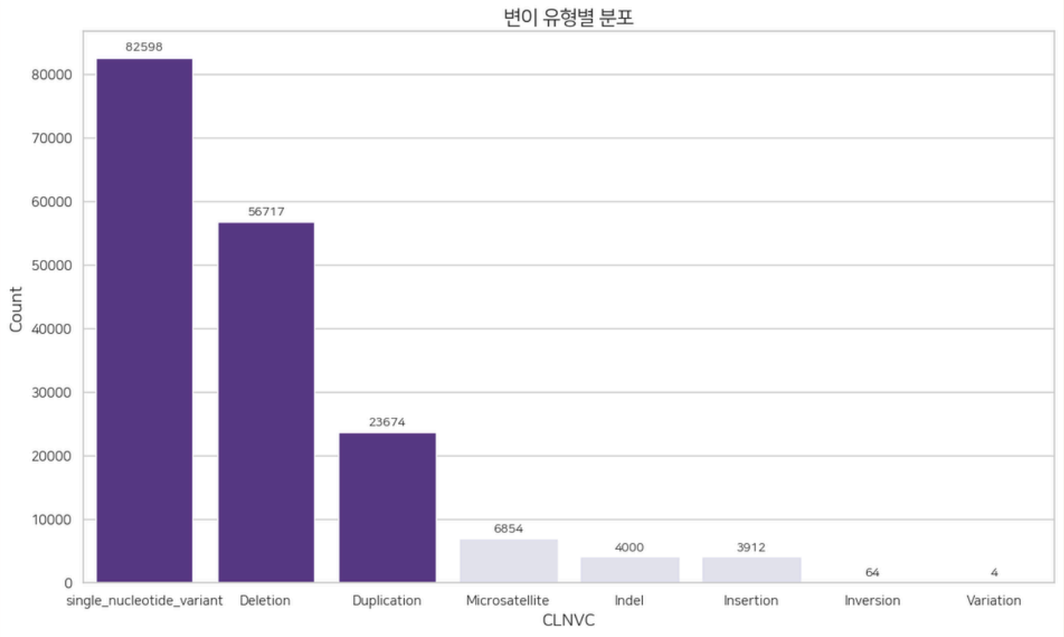

Pathogenic한 변이 내 CLNVC 수

SNV(Single nucleotide variant)가 가장 많음

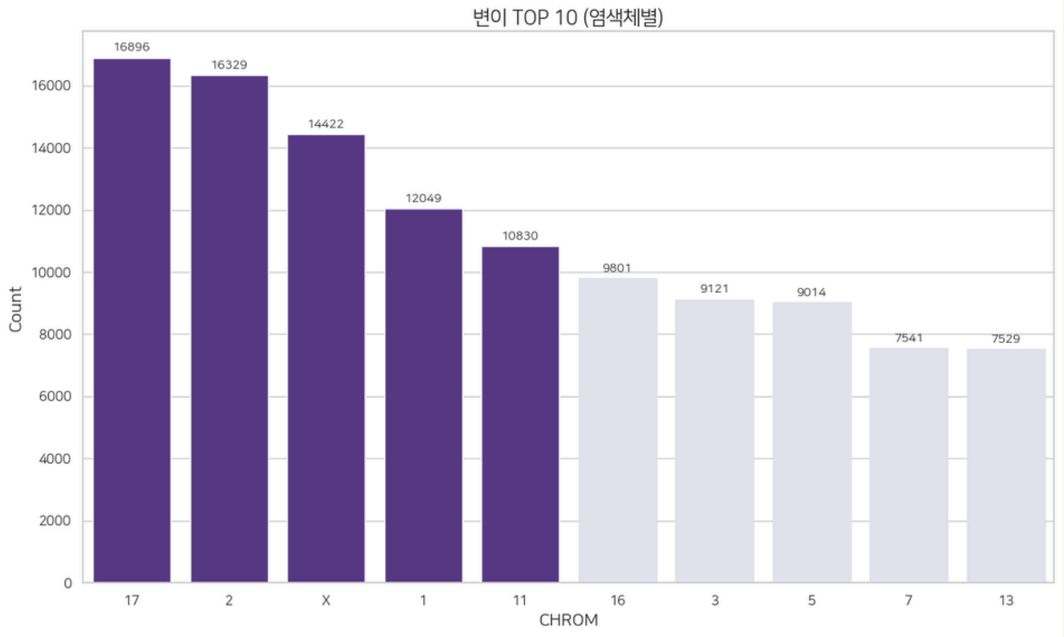

염색체별 변이 수(전체 CLNVC 합계)

상염색체중에서는 17번, 성염색체중에서는 X염색체가 가장 많음

Gene

Pathogenic한 변이가 가장 많은 유전자

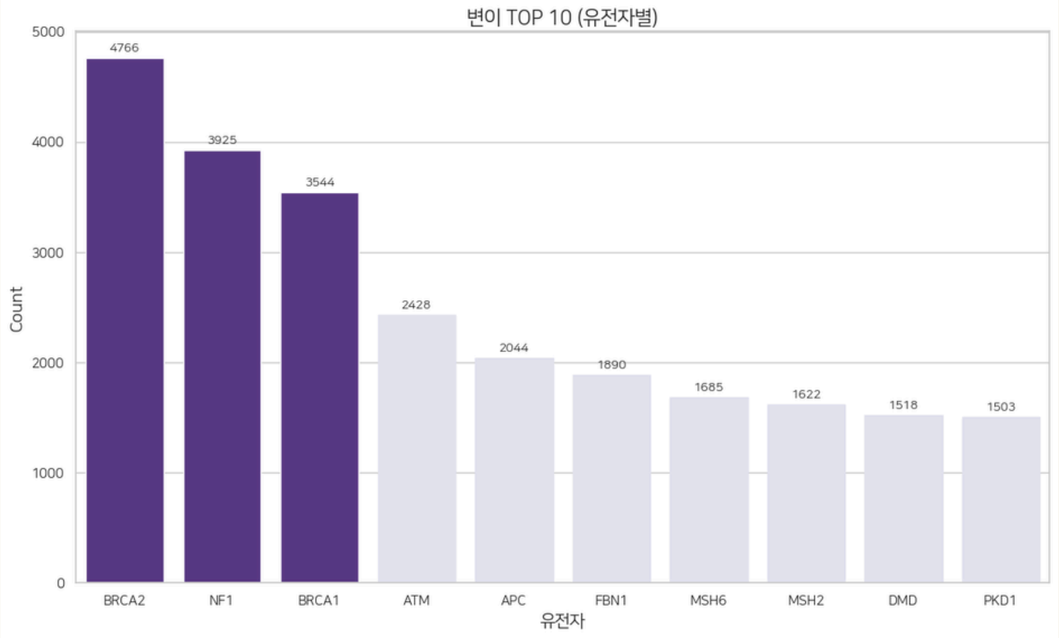

변이가 가장 많은 순(TOP 10)

BRCA2, NF1, BRCA1이 TOP 3

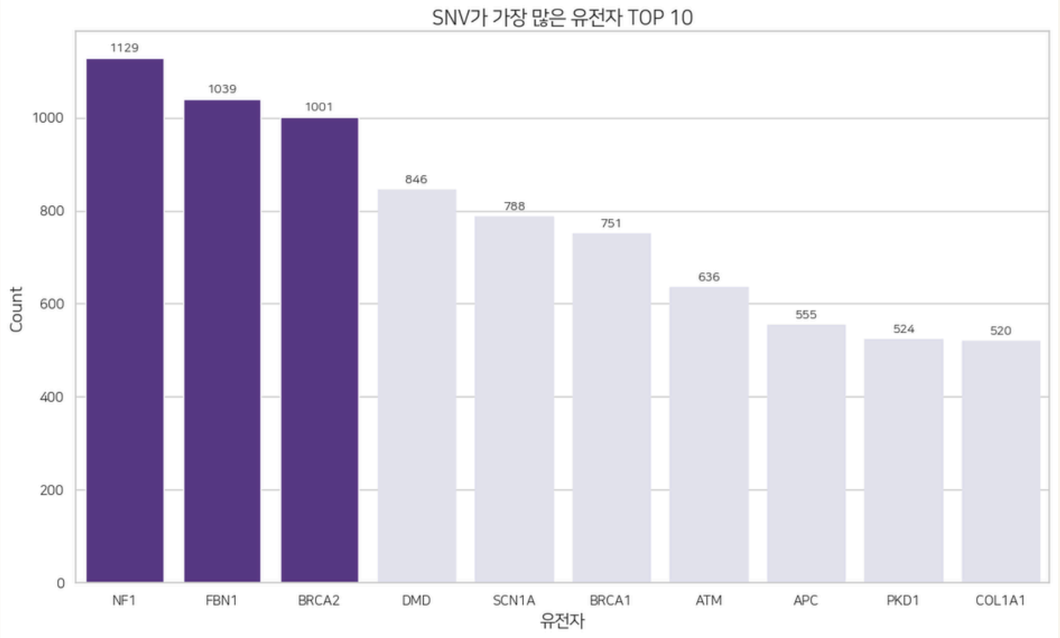

SNV가 가장 많은 순

NF1, FBN1, BRCA2가 TOP3

1

TOP 25 mutation

각 염색체별 변이 TOP 25

염색체 내 유전자들중 가장 변이가 많은 상위 25개의 유전자
각 염색체별 CLNSIG, CLNVC 비율

2

TOP 25 Pathogenic mutation

각 염색체별 Pathogenic TOP 25

염색체 내 유전자들중 가장 Pathogenic한 변이가 많은 상위 25개의 유전자
염색체 내 Pathogenic SNV가 많은 상위 25개의 유전자
Pathogenic한 변이 내 CLNVC 비율

3

Gene filtering

개별 유전자별 필터링

개별 유전자에 대한 변이 유형 및 Pathogenic한 변이 비율

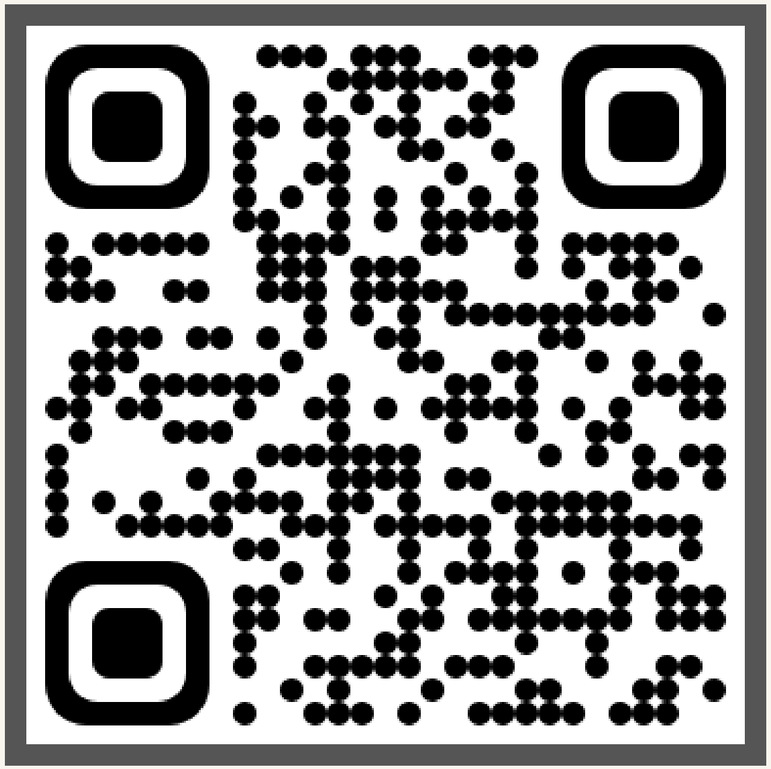

Mail

pokemonms@naver.com
blackholekun@gmail.com

Cellular

+82-10-5027-0328

Github

https://github.com/koreanraichu

Blog

https://koreanraichu.tistory.com/