MSA analysis

SEQUENCE-BASED ANALYSIS OF GENETIC VARIABILITY IN HANTAVIRUS AND INFLUENZA

Table of Contents

1 Introduction

2 Project information

3 Flowchart

4 Data acquisition & Preprocessinbg

5 MSA

6 Shanon entropy

7 Phylogenic tree

8 Contact

Hantavirus

- 신증후출혈열의 원인 병원체로, 오르토한타바이러스속에 속해있다.
- 한국전쟁 당시 휴전선 근처에서 전선이 고착되었을 때 미군을 덮쳤던 수수께끼의 전염병의 정체로, 중공군이 한강 이남으로 넘어오지 못했던 원인이기도 하다.
- 대한민국의 이호왕박사가 한탄강 유역의 등줄쥐 폐조직에서 최초로 발견했다.

Influenza

- 인플루엔자 독감의 원인 병원체로, 오르토믹소바이러스과에 속해있다.
- 바이러스의 표면에 있는 해마글루티닌과 뉴라미니데이즈에 대한 항체의 반응과 그 종류에 따라 아형이 결정되며, HxNx(x는 숫자) 형태로 명명한다.
- 주로 H1, H2, H3과 N1, N2가 인간에게 독감을 일으키는 아형이다.

Project information

Data resource: NCBI

Liblaries

- Biopython
- Pandas
- Seaborn
- Scipy.stats

Statics

- Mann–Whitney U test
- Spearman's Rank Correlation Coefficient

Flowchart

1 → Data acquisition

2 → Preprocessing

3 → MSA analysis

4 → Shanon Entropy

5 → Phylogenic tree
Clustal analysis

1

NCBI Entrez access

Biopython을 이용해 NCBI Entrez 접속

retmax = 300

2

Data acquisition

NCBI에서 바이러스 게놈 DNA 입수

한타바이러스의 경우 게놈 정보 입수 후 Segment S만 따로 필터링 진행

3

MSA analysis

Multiple sequence analysis

Subprocess를 이용한 MSA 진행

Shanon entropy

MSA 결과를 토대로 Shanon Entrophy 계산을 진행

변이가 잘 되는 영역과 보존 영역을 구별하기 위한 분석

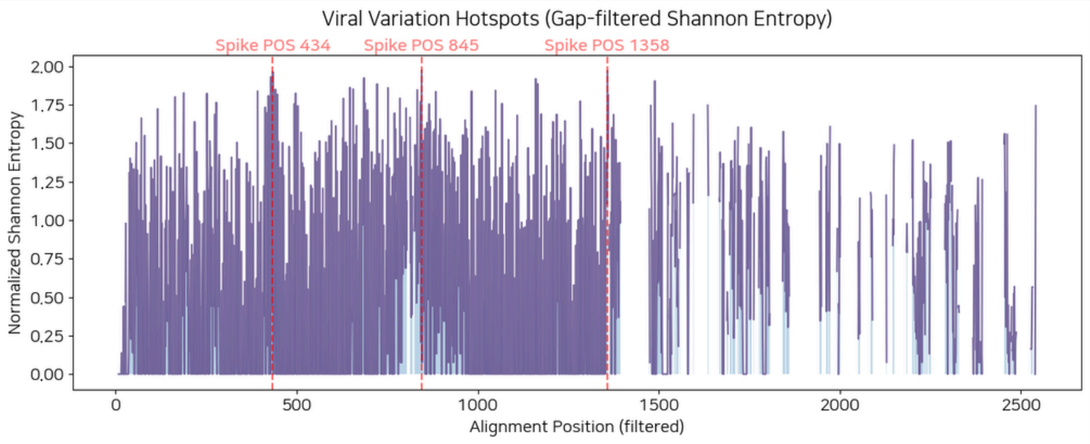

Hantavirus Shanon entropy

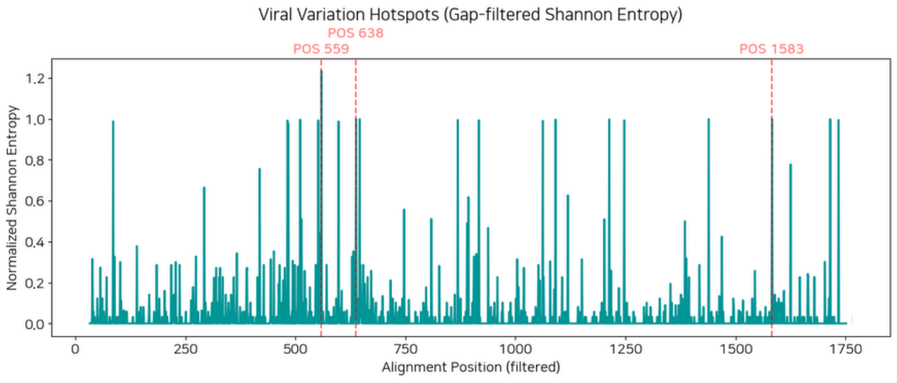

Influenza H3N2 Shanon entrophy

Shanon entropy

Mann-Whitney U test

DNA 염기가 범주형이기때문에 정규성, 평균이 없으므로 비모수검정을 진행

귀무가설: 바이러스의 변이는 무작위적으로 발생하며, 특정 위치에 선호적으로 집중되지 않는다.
대립가설: 바이러스의 변이는 무작위가 아니며, 특정 위치(hotspots)에 유의하게 집중된다.

Mann-Whitney U test

	Window size	Threshold*	U-statics	P-value
Hantavirus	25bp	0.750	291600.0	$p < 1e-10$
Influenza	25bp	0.1175	281607.0	$p < 1e-10$

*window-averaged, normalized entropy 상위 10%

바이러스의 변이는 무작위가 아니며, 특정 위치에 유의하게 집중됨을 확인하였다.

Phylogenic tree

Hantavirus: Mann-Whitney U test
Influenza: Spearman Correlation

[Appendix] Phylogenic tree & Statical raw data

귀무가설: 동일 clade 내 서열 유사도와 서로 다른 clade 간 서열 유사도에는 차이가 없다.
대립가설: 동일 clade 내 서열 유사도가 clade 간 서열 유사도보다 유의하게 높다.

Hantavirus

Mann-Whitney U test & effect_size

U-statics	P-value	Effect size	Rank-biserial
1014127.0	$p < 1e-10$	0.3479	-0.9962

계통수의 동일 clade간 서열 유사도가 clade간 서열 유사도보다 유의하게 높음을 확인

귀무가설: 계통수 구조는 H3N2 해마글루티닌의서열 차이를 반영하지 않는다.
대립가설: 계통수 구조는 H3N2 해마글루티닌의 서열 차이를 반영했다.

Influenza

Spearman Correlation

Spearman ρ	P-value
-0.9680	$p < 1e-10$

계통수 구조가 H3N2 해마글루티닌의 서열 차이를 반영함을 확인

Clustal analysis

k-medoid

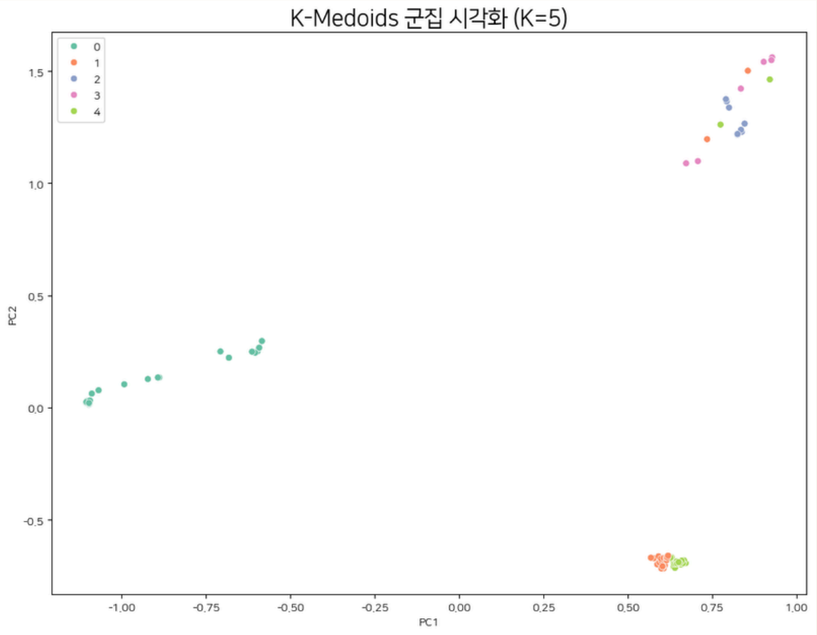

Hantavirus

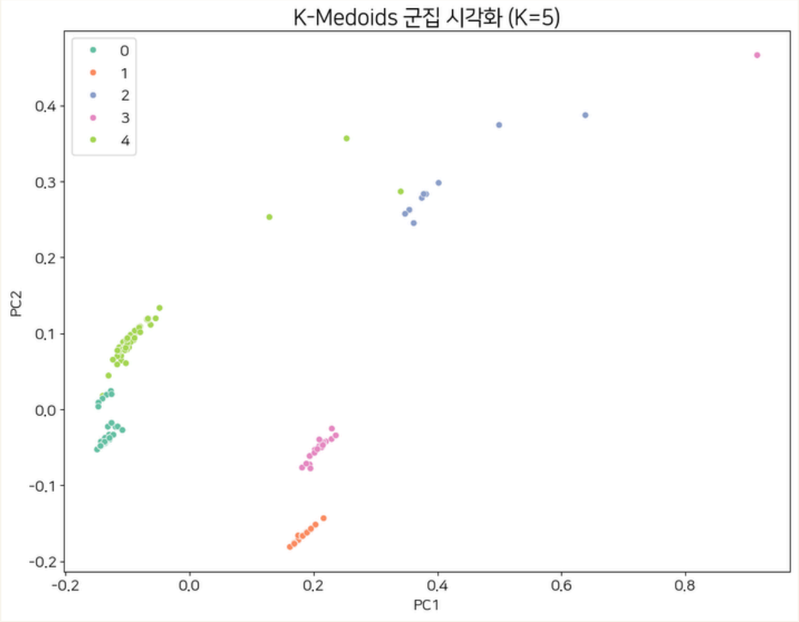

Influenza H3N2

Mail

pokemonms@naver.com
blackholekun@gmail.com

Cellular

+82-10-5027-0328

Github

https://github.com/koreanraichu

Blog

https://koreanraichu.tistory.com/